


정규 스터디

5장 합성곱 신경망 1

최민혁

(지도교수: 양선웅)

한양대학교 ERICA 기계공학과




Intelligent Design
for Engineering
Applications Lab

CNN(Convolutional Neural Network)

- Convolution(합성곱): $(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(\tau - t)d\tau$ (연속) 또는 $(f * g)[n] = \sum_{-\infty}^{\infty} f[k]g[n - k]$ (이산)
- CNN에서 convolution: $S(i, j) = \sum_{m, n} I(i + m, j + n)K(m, n)$


Convolution layer

- ❖ Weight가 격자 형태(filter)로 구성
- ❖ 하나의 filter가 이동하며 convolution을 진행



Hyper parameter(CNN)

- ❖ K: Number of filter
 - ✓ Filter의 수
- ❖ F: Filter size
 - ✓ Filter의 크기
- ❖ S: Stride
 - ✓ 이동하는 칸
- ❖ P: Padding
 - ✓ 가장자리에 0 채우기
 - ✓ 이미지 크기 보존: 이미지 크기로 인한 Layer 깊이 제한 회피
 - ✓ 가장자리 정보 유실 감소: 가장자리의 convolution 참여
- ❖ Pooling size & type
 - ✓ 지정한 size의 영역을 대표할 수 있는 값으로 대체
 - ✓ Max / Average / GAP(Global Average Pooling) 등



CNN 연산 과정

연산 과정

❖ Input

- ✓ 일정 시간, 공간 간격의 균일한 격차로 나타낼 수 있는 데이터
- ✓ 형태: (크기, 채널) e.g. 높이 4 너비 2 RGB: (4,4,3)


❖ Feature Learning

- ✓ Convolution Layer: 채널은 filter의 수만큼 배가 됨
- ✓ 일반적으로 깊은 layer일 수록 채널을 늘림(복잡한 특징 포착)
- ✓ 필터 채널은 데이터와 동일하며 각 채널의 가중치는 서로 다름
- ✓ Feature map은 각 convolution의 합


❖ Fully Connected Layer

- ✓ Feature map 평탄화
- ✓ Output 내용 결정 (분류 / 객체탐지 / 분할)

❖ Output



Feature Learning



$$W_2 = \frac{W_1 - F + 2P}{S} + 1$$


$$W_3 = \frac{W_2 - F}{S} + 1$$

CNN 연산 과정

Output에 따른 분류 (1/3)

❖ 분류

- ✓ Convolution layer 뒤에 Fully connected layer
- ✓ Softmax로 정규화한 1차원 확률 벡터 출력



CNN 연산 과정

Output에 따른 분류 (2/3)

❖ 객체탐지

✓ [객체 존재확률 P , 위치 b , 분류 별 확률 C]로 구성된 벡터 출력

✓ IoU: 두 영역의 중첩 정도를 평가


$$IoU = \frac{Intersection}{Union} \left(= \frac{\text{교집합}}{\text{합집합}} \right)$$

✓ NMS (Non-Maximum Suppression): 신뢰도가 낮거나 겹치는 예측박스 제거


1. 임계값 이하의 점수($P_c, P_c \times C_i$ 등)를 가지는 블록 제거 및 점수에 따라 내림차순 정렬
2. 리스트의 순서대로 박스를 꺼내고, 꺼낼 때 마다 해당 박스와 기준치 이상의 IoU를 가지는 블록을 삭제

✓ Anchor Box: 백지상태에서 객체의 위치를 찾는 대신, 모델이 형태와 크기를 쉽게 미세 조정 할 수 있도록 각 그리드마다 미리 깔아두는 '데이터 기반의 표준 탐색 가이드라인'

1-Stage Detector



2-Stage Detector




CNN 연산 과정

Output에 따른 분류 (2/3)


❖ 객체탐지

- ✓ 1-Stage Detector: 위치추정과 분류를 동시에 진행
빠르고 부정확함
FC layer를 사용하지 않음
Center Point Rule: Feature map은 동일하게 분할한 grid cell에 대응하며, 객체의 정중앙을 포함하는 grid cell만이 의미있는(P_c 가 큰) 벡터를 출력하게 학습
- ✓ 2-Stage Detector: 위치추정 후 해당 영역에서 분류
느리고 정확함
두 갈래의 FC layer (분류, 박스 조정)
RPN(Region Proposal Network): Feature map에 크기와 비율이 다양한 anchor box를 촘촘히 배치해 P 와 박스 보정값 출력. P 가 큰 영역을 RoI(Region of Interest)라 함.
RoI Pooling: RoI를 고정된 크기를 고정된 크기로 변환
- ✓ 겹침 극복
Anchor Box: 1-state detector의 grid cell에 후보군 수만큼 넣음
Soft NMS: NMS의 소거 대상에 대해 소거 대신 감점

1-Stage Detector



2-Stage Detector



CNN 연산 과정

Output에 따른 분류 (3/3)


❖ 분할

- ✓ Flatten 및 FC layer가 없음
- ✓ Encoder로 압축(down sampling), decoder로 복원(up sampling)
- ✓ Decoder: Up sampling → Skip connection 결합 → Convolution + Activation Function (크기 줄이기 또는 정보 섞기)
- ✓ Up sampling 방법: Transposed Convolution / Unpooling / Interpolation + Convolution
- ✓ 채널 수가 클래스 수인 원본 크기의 데이터를 출력 e.g. (원본 가로길이, 원본 세로길이, 클래스 수)
- ✓ Skip Connection: Decoder가 압축하기 전 위치정보를 decoder로 전달해 손실된 위치정보를 보완 (U-Net)

각 down sampling에서 feature map을 하나씩 저장

Decoder의 각 up sampling에서 동일한 해상도를 가지는 feature map과 결합

결합: Concatenation (채널 이어 붙이기, 정보 보존) / Addition (성분 별로 더하기, 효율적 연산)



■ 전이학습

- 이미 학습된 데이터셋을 학습의 시작점으로 설정
- 새로운 데이터 양, 기존 데이터와 유사도 등에 따라 다른 전략을 이용

Feature Extraction

- ❖ Convolution layer를 freeze
- ❖ FC layer를 필요에 따라 수정 후, 추가 학습을 진행

Fine-tuning

- ❖ FC layer를 필요에 따라 수정 후, 일부 또는 전체 레이어를 추가 학습
- ❖ 일반적으로 learning rate를 낮게 설정해 기존 지식을 보호
- ❖ Gradual Unfreezing
 - ✓ 처음에는 FC layer만 학습을 진행함
 - ✓ 필요에 따라 점차 앞쪽 layer를 unfreeze하여 학습을 진행

새 데이터 양	기존 데이터와 유사도	추천 전략
적음	유사함	Feature Extraction
적음	다름	후방 Fine-tuning
많음	유사함	전체 Fine-tuning
많음	다름	전체 Fine-tuning 또는 처음부터 학습 고려

Part 1
CNN

Part 2
CNN 연산

Part 3
Transfer
Learning

Part 4
GNN

GNN(Graph Neural Network)

- Graph: 원소 node와 연결정보 edge로 구성
- 이웃한 node를 이용해 본인을 업데이트

Graph Data 표현

- ❖ Adjacency Matrix (A)
 - ✓ Graph의 연결관계를 표현
 - ✓ 크기: $N \times N$ (N = 노드 개수)
 - ✓ 연결 수로 인한 왜곡 예방 및 스스로에 대한 정보반영을 위한 정규화

$$\hat{A} = D^{-\frac{1}{2}} \cdot (A + I) \cdot D^{-\frac{1}{2}}$$

유형	설명
무방향 그래프	대칭 행렬 ($A[i][j] = A[j][i]$)
방향 그래프	비대칭 행렬 가능
가중치 그래프	0/1 대신 엣지의 가중치(weight) 값 사용
Self-loop 포함	대각선($A[i][i]$)에 1 추가 (자기 자신 정보도 반영)

- ❖ Feature Matrix (H)
 - ✓ 각 node가 가진 정보를 표현
 - ✓ 크기: $N \times F$ (N = 노드 개수, F = 각 노드의 특징 차원 수)

GCN

- ❖ CNN 개념을 graph 구조에 적용

$$H(l + 1) = \sigma(\hat{A} H(l) W(l))$$

Any Questions?

이름 최 민 혁

소속 한양대학교 기계공학과

이메일 mindat@hanyang.ac.kr



*Intelligent Design
for Engineering
Applications Lab*

